

Inteligência Artificial – ICC265

Relatório Prático 3

Lucas Castro, Marcos Guerreiro, Suziane Cundiff

1

1 Introdução

Ao longo dos últimos anos houve uma aumento significativo na disseminação de fake news pelo mundo. Um estudo realizado pela universidade de Oxford, em 2019, mostrou que houve uma aumento de 150% na disseminação de fake news em relação aos dois anos anteriores.

Agora em 2021, nós já podemos ver os impactos que essas informações falsas podem gerar na sociedade, indo desde a difamação de manifestantes que lutam pela democracia como aconteceu na China, levando-os a serem tratados como criminosos até o uso de medicamentos sem eficácia comprovada para a prevenção de uma doença de nível pandêmico como foi tão difundido no Brasil.

Este trabalho tem como objetivo principal apresentar um modelo computacional que receba um texto e indique se o texto pode ser inferido como uma desinformação empírica (fake news). O modelo computacional utilizará redes neurais com representação simbólica.

2 Referencial Teórico

Nessa sessão apresentaremos alguns conceitos essenciais para o entendimento do trabalho.

2.1 Redes Neurais

As redes neurais são algoritmos, modelados a partir da propagação de informação pelos neurônios no cérebro humano, que são projetados para reconhecer padrões, a propagação de informação acontece de forma que esses neurônios interpretam os dados sensoriais por meio de uma espécie de percepção da máquina, rotulando ou agrupando os dados. Eles reconhecem padrões numéricos que são guardados vetorialmente. Todos os dados do mundo real, sejam eles imagens, sons, textos ou series temporais, devem ser traduzidos para esse padrão [1].

Nos últimos anos, as redes neurais artificiais têm sido amplamente utilizadas devido a sua alta capacidade de extração de padrões. Um dos principais obstáculos a serem superados é a necessidade de grandes quantidades de dados para o treinamento, principalmente quando a complexidade do modelo é muito alta.

Os principais componentes que podem treinar uma rede neural são: camadas e seus pesos, que são combinados para formar uma rede, dados de entrada e seus respectivos objetivos, a função de perda que avalia o aprendizado durante o treinamento e o otimizador que determina se o método de aprendizagem continuará. Cada rede possui uma camada de entrada e uma camada de saída. O número de neurônios na camada de entrada deve ser igual ao número de recursos na biblioteca de treinamento.

2.2 Sistemas Neuro-Simbólicos

Atualmente, tem-se dois paradigmas distintos para a representação de informação e aprendizagem, são eles: computação neural e sistemas simbólicos. De acordo com [2], existe um movimento em ascensão para a união desses dois paradigmas, fazendo com que seja possível estudar lógica, combinada com as percepções do conexionismo. Essa união dos paradigmas é conhecida como inteligência artificial neuro-simbólica.

O objetivo dessa união de paradigmas é explorar vantagens de ambos. Sistemas simbólicos possuem a capacidade de explicar seus processos de inferência utilizando prova de teoremas e sua capacidade declarativa de linguagem para representação de conhecimento enquanto computação neural possui um grande poder de paralelismo e generalização através das redes neurais.

2.3 Logic Tensor Network (LTN)

Agentes de Inteligência Artificial baseiam o aprendizado de acordo com a representação de mundo ao seu redor ao passo que raciocina o conhecimento aprendido para tomada de decisões [3]. Como abordado em [4] a aprendizagem de máquina e área de inteligência artificial são tratadas como áreas de conhecimentos distintas, onde, respectivamente, uma o conhecimento é baseado na informação inerente aos dados e outra baseada na lógica proposta.

Logic Tensor Networks [4] é um modelo computacional neuro-simbólico para aprendizado e raciocínio através de um formalismo lógico chamado Real Logic. Dessa forma, ele é descrito por lógica de primeira ordem para aprendizado profundo.

Em Real Logic, as fórmulas possuem um valor verdade que esta entre 0 e 1 e as constantes lógicas são interpretadas como vetores de características de números reais. Assim, é possível integrar o raciocínio dedutivo em uma Knowledge Base ao aprendizado relacionado baseado em dados fazendo com que seja possível executar as seguintes tarefas: agrupamento de dados, aprendizagem relacional, resposta a consultas, aprendizagem semi-supervisionada, regressão e aprendizagem incorporada.

3 Problema

3.1 Definição

Dado um texto, identifique se ele possui ou não possui desinformação empírica.

3.2 Abordagem geral

Foi utilizado um sistema neuro-simbólico para fazer uma aprendizagem supervisionada de 100 textos.

3.3 Obtenção dos textos

Os 100 textos e suas classificações foram obtidos no site [aosfatos](#), um dos sites dados como material complementar do trabalho. Esse site realiza a classificação dos textos em verdadeiros e falsos. Essas mesmas classificações foram utilizadas no treinamento. Foram selecionados 50 textos classificados como verdade e 50 textos classificados como mentira.

3.4 Treinamento

Para o treinamento foi utilizado um modelo LTN. Utilizando como base os exemplos recomendados pelo professor: [1](#), [2](#) e [3](#).

O código foi implementado em python e se encontra em [link](#). Foi utilizada a biblioteca de LTN recomendada pelo professor [link](#).

Foram utilizados 70% dos textos pra treino e 30% para testes. As palavras dos textos foram convertidas para vetores de pontos flutuantes utilizando Word2Vec [5]. O modelo de Word2vec utilizado foi o da biblioteca gensim do python com o corpus mac_morpho.

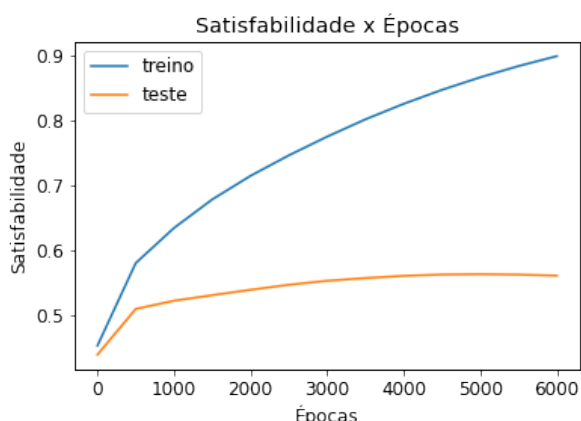
Foram utilizadas as seguintes regras como axiomas do LTN.

1. Para todo texto verdadeiro X, Valido(X) é verdade
2. Para todo texto falso Y, not(Valido(Y)) é verdade

O modelo LTN foi treinado com 32 batches, 10000 épocas, learning_rate de 0.0000005, p=2 (nos operadores lógicos) e o otimizador adams.

4 Análise dos Resultados

Como foi dito anteriormente, treinamos o modelo LTN para identificar desinformação empírica em textos. Segue a satisfabilidade do modelo no dataset de treino e teste ao longo das épocas:



Somente apresentamos até a 6000ª época, pois após a época 6000 somente o dataset de treino apresenta melhorias. Caracterizando então overfitting no dataset de treino.

Foi obtida uma satisfabilidade de 56,2% no dataset de teste ao final do treinamento (6000ª época).

Tentamos utilizar diferentes valores nos parâmetros do treinamento, mas os parâmetros apresentados foram os que obtiveram os melhores resultados.

5 Conclusão

Nesse trabalho utilizamos um sistema neuro-simbólico para checar se textos possuem desinformação empírica ou não. Para isto utilizamos a classificação realizada por um site de checagem, a biblioteca de LTN e os exemplos [1](#), [2](#) e [3](#). Obtivemos ao final uma satisfabilidade de 56,2%.

References

- [1] Aurélien Géron. Neural networks and deep learning. 2018.
- [2] A.S d'Avila Garcez, K Broda, and D.M Gabbay. Symbolic knowledge extraction from trained neural networks: A sound approach. *Artificial Intelligence*, 125, 2001.
- [3] Leslie G. Valiant. Three problems in computer science. *J. ACM*, 50, 2003.
- [4] Samy Badreddine, Artur Garcez, Luciano Serafini, and Michael Spranger. Logic tensor networks. 2020.
- [5] Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. Efficient estimation of word representations in vector space, 2013.